

Un nuevo acercamiento a la Clasificación de Pacientes con Riesgo Cardiovascular usando SNN.

1st Santiago Andrés Rocha, 2nd Sebastián Rojas Bueno

Escuela Colombiana de Ingeniería Julio Garavito, Bogotá, Colombia

santiago.rocha-c@mail.escuelaing.edu.co, sebastian.rojas-bu@mail.escuelaing.edu.co

Resumen—En este artículo se describe un proyecto que se enfocó en la construcción de modelos de Redes Neuronales Simples (SNN) para clasificar pacientes en dos categorías, 'pacientes propensos' y 'pacientes no propensos' a sufrir ataques cardíacos. Se combinaron técnicas de procesamiento de datos médicos con las capacidades de las Redes Neuronales para lograr una alta exactitud en la clasificación y tiempos de ejecución eficientes.

El proyecto utilizó un enfoque en el que se tomaron datos médicos previamente etiquetados en un conjunto de datos conocido, 'Heart Attack Analysis & Prediction Dataset' [12], los cuales fueron utilizados para entrenar y evaluar varios modelos. Se aplicaron técnicas de preprocesamiento de datos para ajustar la información, así como para mejorar el rendimiento y resultados obtenidos.

Para la construcción de los modelos se experimentó con el framework Keras y se comparó con un framework implementado por nosotros, lo que permitió el procesamiento de los datos médicos. A través de esta experimentación y ajuste de los hiperparámetros, se logró alcanzar una **exactitud** de clasificación superior al 85 %.

También se consideraron los **tiempos de ejecución** durante la experimentación y se logró mantenerlos por **debajo de 10 minutos**, lo que asegura una respuesta rápida en la clasificación de los pacientes.

Los resultados obtenidos demuestran que el enfoque propuesto es efectivo para la clasificación, brindando una solución precisa y eficiente gracias al cumplimiento de las métricas optimizadas y alcanzadas por uno de los modelos creados. Este proyecto y en particular el modelo seleccionado finalmente tiene potenciales aplicaciones en la industria de la salud, mejorando la identificación temprana de pacientes propensos a sufrir ataques cardíacos y proporcionando análisis automatizados y rápidos.

Index Terms—Prevención y detección, redes neuronales simples, clasificación, ataques cardíacos, intervención temprana

I. INTRODUCCIÓN

En el campo de la medicina, la identificación temprana de pacientes propensos a sufrir ataques cardíacos es de vital importancia para brindar un tratamiento adecuado y reducir los riesgos asociados con esta enfermedad. En la actualidad, el uso de técnicas de aprendizaje automático se ha vuelto fundamental para abordar este desafío, permitiendo la clasificación automatizada de pacientes en categorías de "propensos." "no propensos." a sufrir ataques cardíacos.

En este artículo, se presenta un estudio exhaustivo que tiene como objetivo resolver el problema de clasificación de pacientes propensos o no a sufrir ataques cardíacos, utilizando diferentes modelos de redes neuronales simples y técnicas de ajuste de datos. Se exploró la eficacia de diversas estrategias, como la redistribución de los datos y la normalización, con

el fin de mejorar la exactitud de los modelos y garantizar un tiempo de ejecución óptimo.

El estudio se basó en un conjunto de datos previamente recopilados, que incluía información clínica de pacientes y su historial médico relevante, como la edad, el sexo y mediciones respiratorias y cardiovasculares. Se llevaron a cabo experimentos utilizando varios modelos de redes neuronales simples, aplicando ajustes y optimizaciones específicas a cada uno, principalmente en los hiperparámetros.

Además, se realizaron ajustes en el dataset para equilibrar la distribución de los conjuntos de datos a utilizar y prevenir cualquier sesgo que pudiera afectar la exactitud de los modelos. Asimismo, se aplicó una técnica de normalización para garantizar que las características de los datos estuvieran en la misma escala y así mejorar la capacidad de generalización.

Después de realizar experimentos exhaustivos y analizar los resultados, se seleccionó el modelo que cumplió con las métricas establecidas. La métrica a optimizar fue la exactitud, con el objetivo de lograr una clasificación precisa superior al 85 %, mientras que la métrica a satisfacer fue el tiempo de ejecución, con una restricción de no exceder los 10 minutos.

A continuación, explicaremos cómo dimos lugar a nuestra investigación y experimentación, brindando información detallada sobre la metodología utilizada, decisiones tomadas y justificaciones de las mismas, así como brindaremos los resultados obtenidos y su respectiva explicación.

II. ESTADO DEL ARTE

II-A. Marco Teórico

Los problemas de clasificación de pacientes propensos o no a sufrir ataques cardíacos tienen un trasfondo histórico significativo en el campo de la medicina y la investigación cardiovascular. Durante décadas, los médicos y científicos han buscado formas de identificar y predecir el riesgo de enfermedades cardíacas, con el objetivo de brindar una atención médica más temprana y efectiva a los pacientes en riesgo. [1]

En el pasado, la evaluación del riesgo cardiovascular se basaba en factores de riesgo tradicionales, como la presión arterial, el colesterol, el tabaquismo, la diabetes y la obesidad. Sin embargo, estos factores de riesgo se basaban en medidas aisladas y no tenían en cuenta la complejidad de las interacciones entre ellos. [2]

Con el avance de la tecnología y el surgimiento del aprendizaje automático y la minería de datos en el ámbito de la salud, se ha abierto la puerta a nuevas oportunidades para abordar

los problemas de clasificación de pacientes propensos a enfermedades cardíacas. Estos enfoques permiten analizar grandes conjuntos de datos médicos, incluidos registros electrónicos de salud, datos de pruebas de laboratorio y características clínicas, con el objetivo de identificar patrones y relaciones que pueden predecir el riesgo cardiovascular de manera más precisa. [3]

El desarrollo de algoritmos de aprendizaje automático ha permitido a los investigadores construir modelos predictivos más sofisticados y precisos. Estos modelos utilizan características clínicas y datos demográficos de los pacientes, así como biomarcadores y resultados de pruebas médicas, para predecir la probabilidad de que un paciente desarrolle enfermedades cardíacas en el futuro. [4]

La creciente disponibilidad de grandes conjuntos de datos de salud y los avances en la capacidad computacional han facilitado la aplicación de técnicas de aprendizaje automático en el campo de la cardiología. Además, la integración de datos genéticos y la incorporación de datos longitudinales a lo largo del tiempo han ampliado las posibilidades de mejorar la exactitud en la clasificación de pacientes.

Algunos aspectos importantes de los ataques al corazón y las medidas que se pueden tomar para prevenirlos se clasifican en los siguientes puntos:

- Factores de riesgo no modificables: Existen ciertos factores de riesgo para los ataques al corazón que no pueden ser modificados, como la edad, el sexo y la historia familiar. Las personas mayores de 45 años y los hombres tienen un mayor riesgo de sufrir un infarto de miocardio, así como aquellos con antecedentes familiares de enfermedades cardiovasculares.
- Factores de riesgo modificables: Los factores de riesgo modificables incluyen el tabaquismo, la hipertensión arterial, la diabetes, la hipercolesterolemia, la obesidad, la inactividad física y el estrés. Estos factores pueden ser controlados mediante cambios en el estilo de vida, como dejar de fumar, mantener una dieta saludable, hacer ejercicio regularmente y controlar la presión arterial y el nivel de colesterol.
- Prevención primaria: La prevención primaria se refiere a medidas que se pueden tomar para prevenir el infarto de miocardio en personas que no tienen antecedentes de enfermedades cardiovasculares. Las medidas incluyen la adopción de hábitos de vida saludables, como una dieta equilibrada y actividad física regular, y el control de los factores de riesgo, como la hipertensión arterial y la diabetes.
- Prevención secundaria: La prevención secundaria se refiere a medidas que se pueden tomar después de un infarto de miocardio para prevenir futuros eventos cardiovasculares. Estas medidas incluyen cambios en el estilo de vida, como dejar de fumar y hacer ejercicio regularmente, así como el uso de medicamentos para reducir el riesgo de nuevos infartos, como aspirina, estatinas y beta-bloqueantes.

La prevención de los ataques al corazón implica la identificación y el control de los factores de riesgo modificables, así como la adopción de hábitos de vida saludables y el

seguimiento médico regular para detectar y tratar cualquier problema de salud cardiovascular.

La investigación en este campo continúa evolucionando, con el objetivo de mejorar aún más la exactitud y confiabilidad de los modelos de clasificación de riesgo cardiovascular. A medida que se recopilan y analizan más datos de pacientes, se espera que se descubran nuevos biomarcadores y se desarrollen modelos más sofisticados que permitan una identificación temprana y precisa de los pacientes propensos a sufrir ataques cardíacos. [5]

Precisamente para mayor exactitud y confiabilidad, las estrategias de aprendizaje automático como las Redes Neuronales han permitido alcanzar resultados para el apartado médico que demuestran su poder y eficiencia, siendo capaces de abstraer características relevantes previamente no especificadas que traen nuevos acercamientos a los problemas que esta área trae consigo. Particularmente, y hablando de problemas de clasificación, es necesario hablar de las Redes Neuronales Simples (SNN).

Las redes neuronales simples, también conocidas como perceptrones multicapa, son un tipo de modelo de aprendizaje automático ampliamente utilizado en problemas de clasificación. Estas redes están inspiradas en el funcionamiento del sistema nervioso humano y se basan en el concepto de neuronas artificiales interconectadas.

Las redes neuronales simples constan de múltiples capas de neuronas interconectadas. La primera capa se conoce como capa de entrada y recibe las características o variables predictoras del problema de clasificación. Luego, las señales se propagan a través de una o varias capas ocultas, que procesan la información y extraen características relevantes del conjunto de datos. Finalmente, la última capa, conocida como capa de salida, produce las salidas o las predicciones del modelo. [6]

Cada neurona en una red neuronal simple realiza una operación lineal y no lineal en las entradas recibidas. La operación lineal consiste en una combinación lineal ponderada de las entradas, seguida de la aplicación de una función de activación no lineal. La función de activación introduce la no linealidad en la red, permitiendo que el modelo aprenda relaciones y patrones complejos en los datos.

Para problemas de clasificación, la capa de salida de la red neuronal simple suele estar compuesta por neuronas con funciones de activación que producen salidas en forma de probabilidades o distribuciones de clase. Por ejemplo, en el caso de una clasificación binaria como la que trabajamos en este artículo, la función de activación puede ser la función sigmoide, que produce una salida entre 0 y 1 que puede interpretarse como la probabilidad de pertenecer a una clase determinada. [7]

Para implementar redes neuronales simples en el procesamiento de datos de igual tamaño y la clasificación de pacientes propensos o no de sufrir ataques cardiovasculares, un framework ampliamente utilizado es Keras. Keras es una biblioteca de código abierto escrita en Python que proporciona una interfaz de alto nivel para construir y entrenar redes neuronales de manera eficiente. Además, proporciona una variedad de métodos e hiperparámetros ajustables que permiten de manera sencilla y casi intuitiva construir las redes que deseamos. [9]




Figura 1. Ejemplo de una red neuronal simple. [8] Esta red se compone de dos entradas x_1 y x_2 , una capa oculta de 16 neuronas c_1, c_2, \dots, c_{16} , y una única neurona en la capa de salida.

Es relevante mencionar el optimizador 'Adam' y la función de pérdida 'Binary Crossentropy', dos componentes esenciales en el entrenamiento de redes neuronales simples (SNN) en Keras, y componentes importantes en la implementación de los modelos que posteriormente explicaremos.

- **Optimizador Adam:** Adam (Adaptive Moment Estimation) es un algoritmo de optimización ampliamente utilizado en el entrenamiento de redes neuronales profundas, y está disponible como optimizador en la biblioteca de Deep Learning Keras. En sí, combina las ideas de los algoritmos de optimización de Gradiente Descendente Estocástico (SGD) y AdaGrad para proporcionar una eficiente actualización de los pesos de la red.
- **Pérdida Binary Crossentropy:** La pérdida `binary_crossentropy`, también conocida como entropía cruzada binaria, es una función de pérdida comúnmente utilizada en problemas de clasificación binaria, como la clasificación de reviews de películas en positivas o negativas. Esta función de pérdida mide la discrepancia entre las etiquetas verdaderas y las predicciones del modelo. Cuanto menor sea el valor de la pérdida `binary_crossentropy`, más cercanas serán las predicciones del modelo a las etiquetas verdaderas [11].

II-B. Trabajo Relacionado

En cuanto a trabajo relacionado, es importante hablar tanto de datasets y conjuntos de datos relacionados y usados en este tipo de problemas, así como de soluciones tecnológicas que se han dado y se encuentran de forma pública. Hablaremos de ambos aspectos a continuación:

- **Datasets:**
Los datos que tendremos en cuenta para la clasificación fueron tomados del dataset 'Heart Attack Analysis & Prediction Dataset' de Kaggle, son enunciados a continuación:
 - age: Edad del Paciente, siendo un número entero.
 - sex: Sexo del Paciente, siendo 1 para Hombre y 0 para Mujer.

- cp: Indica la presencia de Dolor en el Pecho con 1, o 0 si no presenta.
- trestbps: Presión sanguínea en reposo, con mediciones normales mayores a 100 mmHg.
- chol: Colesterol en sangre medido en mg/dl
- fbs: Azúcar en sangre en ayunas, siendo 1 si el azúcar es $> 120mg/dl$, 0 si no.
- restecg: Resultados electrocardiográficos en reposo, con valores enteros entre 0 y 2.
- thalachh: Ritmo cardíaco máximo alcanzado.
- exng: Angina inducida por el ejercicio, con 1 indicando si hubo Angina, 0 en otro caso.
- oldpeak: Pico previo, referente a mediciones tomadas previamente, no presentadas en el Dataset
- slp: Incremento en ritmo cardíaco inducido por ejercicio, medido con enteros entre 0 y 2.
- caa: Número de vasos mayores, en referencia al corazón (0-4).
- thall: Ritmo de thal, desorden en la sangre causado por enfermedad *Thalassemia*.
- output: 1 si el paciente es propenso a sufrir ataques cardíacos, 0 si no.

A continuación, presentamos un ejemplo de cómo se ve el Dataset en cuestión:

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slp	caa	thall	output
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	56	1	2	130	256	1	0	142	1	0.6	1	1	1	0
2	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
3	48	1	1	110	229	0	1	168	0	1.0	0	0	3	0
4	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
...
298	62	0	0	140	268	0	0	160	0	3.6	0	2	2	0
299	38	1	2	138	175	0	1	173	0	0.0	2	4	2	1
300	67	1	0	120	229	0	0	129	1	2.6	1	2	3	0
301	38	1	2	138	175	0	1	173	0	0.0	2	4	2	1
302	67	1	0	160	286	0	0	108	1	1.5	1	3	2	0

Figura 2. Ejemplo del Dataset. [12]

- **Soluciones Relacionadas:**
Existen varios trabajos de investigación que han utilizado redes neuronales simples para la clasificación de pacientes con problemas del corazón. A continuación, presentamos dos de ellos como ejemplos:
 1. 'Clasificación de Pacientes con Riesgo Cardiovascular usando SNN' [13] (2023): En este estudio, del que somos autores y creadores, implementamos una red neuronal simple para la clasificación de pacientes con enfermedad cardíaca. Utilizamos este mismo dataset 'Heart Attack Analysis & Prediction Dataset' y logramos una exactitud del 88.462 % en la clasificación de pacientes para el conjunto de entrenamiento tras experimentar con modelos de redes neuronales simples que no varían lo suficiente para que los resultados varíen significativamente. No hubo normalización de los datos, ni se tuvo en cuenta la distribución de los mismos, dejando de lado también métricas a satisfacer como el tiempo

de ejecución, por lo que decidimos retomar este trabajo y llevarlo un poco más allá.

2. 'Heart Disease Diagnosis Using Neural Networks' [14] (Diagnóstico de enfermedades cardíacas utilizando redes neuronales), de R. Zimroz et al. (2001): En este estudio, los autores utilizaron una red neuronal simple para la clasificación de pacientes con enfermedad cardíaca. Utilizaron una base de datos con 303 pacientes y 13 variables clínicas, como la edad, el sexo, la presión arterial y el nivel de colesterol. La red neuronal fue entrenada utilizando el algoritmo de retropropagación del error y se logró una exactitud del 86,5 % en la clasificación de pacientes.
3. 'Prediction of Heart Disease Using Artificial Neural Network' [15] (Predicción de enfermedades cardíacas utilizando redes neuronales artificiales), de M. Osareh et al. (2008): En este estudio, los autores utilizaron una red neuronal simple para la clasificación de pacientes con enfermedad cardíaca en tres grupos: sin enfermedad cardíaca, con enfermedad cardíaca no grave y con enfermedad cardíaca grave. Utilizaron una base de datos con 303 pacientes y 13 variables clínicas similares al estudio anterior. La red neuronal fue entrenada utilizando el algoritmo de retropropagación del error y se logró una exactitud del 85 % en la clasificación de pacientes.

Como podemos ver, las redes neuronales simples pueden utilizarse para la clasificación de pacientes con problemas del corazón. Hay muchos otros estudios y aplicaciones en este campo, ya que las redes neuronales son una herramienta prometedora para ayudar a los médicos a tomar decisiones más precisas y personalizadas en el diagnóstico y tratamiento de enfermedades cardíacas.

III. METODOLOGÍA

La metodología para el desarrollo de la solución se planteó de la siguiente forma:

1. Seleccionar el dataset a trabajar.
2. Pensar en el tipo de problema.
3. Analizar el tipo de datos a utilizar como fuente.
4. Considerar una solución con redes neuronales.
5. Considerar qué tipo de red neuronal convendría más.
6. Buscar trabajo relacionado para ayudarnos a comenzar.
7. Empezar a desarrollar la solución.

A continuación, describiremos nuestro desarrollo para cada una de estas etapas en nuestra metodología:

1. Seleccionar el dataset a trabajar:
En esta etapa, se eligió el conjunto de datos que se utilizaría para entrenar el modelo de clasificación de pacientes propensos o no a sufrir ataques cardíacos. Se debería seleccionar un conjunto de datos lo suficientemente grande y diverso para permitir que el modelo tuviese la capacidad de entrenarse correctamente. Adicionalmente, sería necesario revisar los datos que este contenga, ver cómo son traídos y enseñados, para poder

ir pensando en cómo procesar la información o si es necesario 'arreglarla'.

2. Pensar en el tipo de problema:
Se definió el problema de clasificación, es decir, el objetivo del proyecto era desarrollar un modelo de clasificación que pueda tomar las mediciones y sintomatología de pacientes y determinar si son propensos o no a sufrir ataques cardíacos.
3. Analizar el tipo de dato a utilizar como fuente:
Se analizó el tipo de datos que se utilizarían como fuente para el modelo de clasificación. En este caso, se utilizaron valores numéricos sin rangos especificados, más allá que todos son reales enteros positivos, correspondientes a mediciones, síntomas, y frecuencias (datos médicos etiquetados).
4. Considerar una solución con redes neuronales:
Se decidió utilizar una solución basada en redes neuronales para abordar el problema de clasificación. Esto se debió a que las redes neuronales han demostrado ser eficaces en problemas de clasificación.
5. Considerar qué tipo de red neuronal convendría más:
Se analizaron diferentes tipos de redes neuronales y se decidió utilizar una red neuronal simple (SNN), por las características y ventajas previamente especificadas.
6. Buscar trabajo relacionado para ayudarnos a comenzar:
Se investigaron trabajos relacionados para obtener ideas y conocimientos sobre el desarrollo de un modelo de clasificación de reviews utilizando redes neuronales simples, finalmente decidiendo utilizar nuestro trabajo previamente implementado [13]. Partiendo de este primer trabajo, determinamos la **métrica a optimizar de Exactitud**, que debe ser **superior al 85 %**, y añadiríamos la **métrica a Satisfacer de Tiempo de ejecución inferior a 10 minutos**.
7. Empezar a desarrollar la solución:
Finalmente, se comenzó a desarrollar la solución utilizando una SNN. Para esto y con ayuda tecnológica, se crearía un modelo de clasificación en Python, principalmente con la ayuda del framework Keras y otras herramientas para su análisis y visualización., incluyendo a modo de verificación y complemento el uso de un framework desarrollado por nosotros [14].

Una vez se terminen estos pasos, y a modo de mayor experimentación, se plantean diferentes modelos similares con cambios sutiles para validar el mejor de entre los mismos, así como decisiones sobre el dataset y su forma de entregar los datos, en búsqueda de mejorar los resultados de los modelos. Más adelante analizaremos y explicaremos cada uno de los modelos planteados, y los resultados obtenidos, determinando cuál resulta ser mejor con base en nuestras métricas de Exactitud y Tiempos de Ejecución. Esto corresponde con los siguientes pasos, que nos permitirían ya a nivel práctico jugar con los modelos de solución, ajustarlos, experimentar y demás.

- Análisis de los datos.
- Diseñar el modelo de red neuronal.
- Pruebas y análisis de resultados.
- Optimización / Regularización.




Figura 4. Distribución inicial de los datos para el conjunto de Entrenamiento, donde evidenciamos una diferencia de 88 pacientes propensos más que los 47 no propensos.




Figura 6. Distribución inicial de los datos para el conjunto de Pruebas, donde evidenciamos una diferencia de 12 pacientes no propensos más que los 9 propensos.




Figura 5. Distribución inicial de los datos para el conjunto de Validación, donde evidenciamos una diferencia de 49 pacientes no propensos más que los 21 propensos.




Figura 7. Distribución inicial de los datos para el conjunto de Entrenamiento, donde evidenciamos una distribución homogénea.

Las nuevas distribuciones corresponden a las figuras 7, 8 y 9.

Una vez tenemos nuestros conjuntos de datos seleccionados y distribuidos, procedemos entonces con la red.

2. Diseñar el modelo de red neuronal:

Tomamos las características más adecuadas para el problema de clasificación, principalmente hablando del tipo de función de activación. Para problemas de clasificación, donde se espera independencia entre cada uno de los pacientes, se tomaría como predeterminado las siguientes características:

- El número de neuronas en la capa de entrada correspondería al número de registros (columnas) del Dataset seleccionado relacionados con información

médica y científica del paciente, siendo 13 datos a tener en cuenta.

- El número de neuronas en la capa de salida correspondería al número de registros (columnas) del Dataset seleccionado destinadas a ser los resultados de la clasificación, siendo la última columna a tener en cuenta.
- La función de activación para la única neurona de la capa de salida correspondería a una función Sigmoide, pues es acorde al problema de clasificación con independencia entre las salidas (refiriéndonos al hecho de que el resultado de un paciente debe ser independiente/indiferente del resultado de otro paciente)
- La Métrica a Optimizar corresponde a la Exactitud, o accuracy.

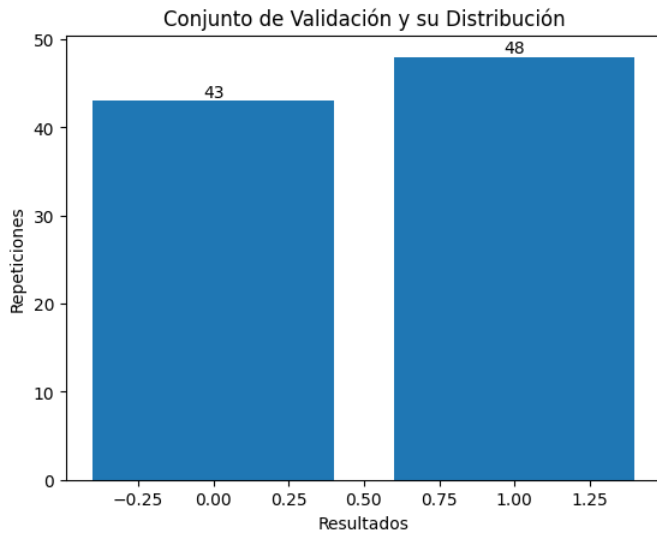


Figura 8. Distribución inicial de los datos para el conjunto de Validación, donde evidenciamos una distribución homogénea.

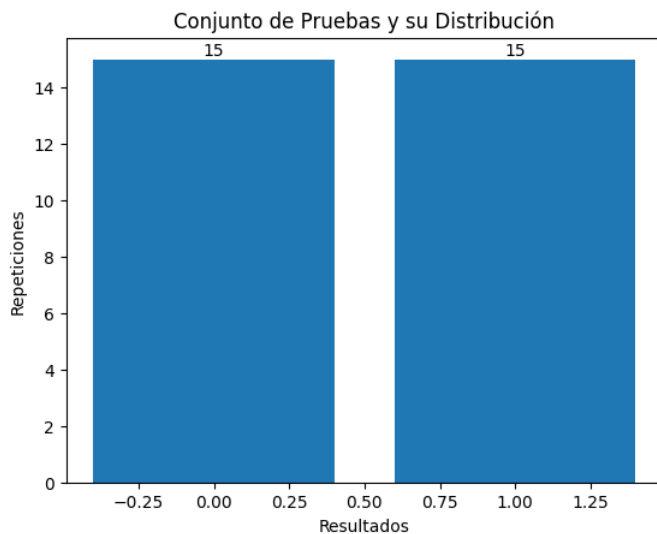


Figura 9. Distribución inicial de los datos para el conjunto de Pruebas, donde evidenciamos una distribución homogénea.

- La Pérdida a utilizar corresponde a la Entropía Cruzada Binaria, o Binary Crossentropy (Pues es un problema de clasificación binaria, sí o no).
- Ritmo de aprendizaje por defecto, correspondiente a 0.01 .
- Por último, y debido al volumen de datos, tendríamos que usar una red profunda dejando de lado al modelo del perceptrón, decisión justificada con experimentación hecha con el mismo que más adelante expondremos.

Planteamos 4 modelos en Keras y un modelo finalmente con nuestro Framework (al que nos referimos como Modelo X), cuyas características son las presentes en el cuadro II. Estos modelos se plantearon con base en nuestro trabajo anterior, y nos aventuramos a jugar más con el número de capas ocultas y el número de neuronas

en cada una de ellas, teniendo como factor principal la profundidad de la red.

Cuadro II
MODELOS Y SUS DIFERENCIAS

Modelo	No. de Capas	F. Activación Oculta	No. neuronas c/u
Modelo 1	0	N.A	N.A
Modelo 2	2	relu	9, 5
Modelo 3	4	relu	11, 9, 5, 5
Modelo 4	6	relu	11, 13, 13, 13, 11, 3
Modelo X	4	relu	11, 9, 5, 5

3. Entrenamiento de los modelos:

En el que utilizamos el conjunto de datos de Entrenamiento preprocesados, teniendo por un lado los datos originales y los normalizados, y por otro lado los datos mal distribuidos y los bien distribuidos.

Para entrenar los modelos, retomamos los valores experimentales de Épocas utilizados en nuestro trabajo anterior, siendo 500 épocas por modelo, y se conseguiría la optimización de los pesos de las neuronas así como de sus sesgos con el objetivo de minimizar el error de clasificación en el conjunto de entrenamiento.

4. Evaluación del modelo:

Para el que es fundamental primero recordar cómo se evaluarían y medirían los resultados que se obtuvieron. Tratándose de un problema de clasificación, se definieron las siguientes características:

- Función de pérdida/costo:
Entropía Cruzada binaria (comúnmente utilizada para este tipo de problemas)
- Métrica a Optimizar:
Exactitud, para verificar qué tan diferentes serían los resultados obtenidos contra los resultados que esperamos obtener. Con base en un estudio publicado en el Journal of the American Medical Association en 2019, conocemos que los cardiólogos en los Estados Unidos tuvieron un rango de diagnóstico correcto del 90,3 % al 94,1 % para la enfermedad coronaria y del 73,3 % al 84,3 % para la insuficiencia cardíaca. Otros estudios han encontrado que la exactitud del diagnóstico puede variar según la experiencia del cardiólogo y la complejidad de la enfermedad. Por lo tanto, decidimos apuntar a una exactitud superior al 85 % .
- Métrica a Satisfacer:
Tiempo, definiendo tiempos de ejecución por modelo inferiores a 10 minutos.

Una vez definidas, se utilizó el conjunto de datos de Validación para evaluar el rendimiento del modelo. Se podría también emplear una técnica de validación cruzada para aumentar la confiabilidad de los resultados, donde probamos diferentes modelos construidos para determinar cuál sería el mejor seleccionable para cumplir con la clasificación (Lo tendremos en cuenta para un trabajo futuro).

5. Optimización del modelo:

Donde con las diferencias entre parámetros de los modelos, y teniendo como optimizador de los modelos hechos con Keras a Adam, realizamos la selección de un modelo final. Para este punto, tomamos la decisión de quedarnos con uno de los modelos experimentados, siendo aquel que mejores resultados obtuvo tanto en Entrenamiento como en Validación, con los datos bien distribuidos o no, con los datos normalizados o no. En resumen, el modelo y las condiciones ganadoras fueron las que se evidencian en el cuadro III.

Cuadro III
MODELOS SELECCIONADO

Modelo Seleccionado	Distribución Correcta	Datos Normalizados
Modelo n	SI	SI

Más adelante en el apartado de resultados, explicaremos el porqué de la selección y justificaremos la misma con cifras específicas aclaratorias.

6. Pruebas y Análisis de Resultados:

Momento en el que con pruebas del modelo optimizado, utilizamos el conjunto de datos de Prueba. Analizamos los resultados obtenidos y determinamos su relevancia y aplicabilidad en la detección temprana de pacientes propensos a sufrir ataques al corazón.

V. RESULTADOS

A nivel general, enseñaremos por cada uno de los modelos los resultados obtenidos para Entrenamiento y Validación, con cada una de las 4 posibles combinaciones que tenemos gracias a la posibilidad de tener sus datos bien distribuidos o no, así como tener los datos normalizados o no.

Las gráficas que enseñaremos corresponden al comportamiento de la Exactitud y la Pérdida en entrenamiento de cada una de las posibilidades mencionadas. Todas estas gráficas tienen en su eje horizontal las Épocas del entrenamiento, siendo 500, y en su eje vertical el resultado obtenido. Al lado izquierdo de cada una se encuentra la Gráfica de Exactitud vs. Épocas, y al lado derecho la Gráfica de Pérdida vs. Épocas.

Los resultados obtenidos por modelo fueron los siguientes:

■ Modelo 1 (Perceptrón):

Resumen de los resultados generales obtenidos, presentes en los cuadros IV, V, VI y VII.

Resultados obtenidos con el conjunto de Entrenamiento, visibles en las gráficas 10, 11, 12 y 13.

Como podemos observar en los resultados, el Modelo 1 sin una buena distribución de los datos y con los mismos normalizados, presente en el cuadro V, supera al resto de las versiones pues tiene mejores resultados en la exactitud del conjunto de Validación indicando que está

Cuadro IV
RESULTADOS MODELO 1, SIN BUENA DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.874	80.22 %
Validación	-	71.429 %

Cuadro V
RESULTADOS MODELO 1, SIN BUENA DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.285	85.714 %
Validación	-	73.626 %

Cuadro VI
RESULTADOS MODELO 1, MEJOR DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.284	91.209 %
Validación	-	71.429 %

Cuadro VII
RESULTADOS MODELO 1, MEJOR DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.314	87.363 %
Validación	-	72.527 %




Figura 10. Resultados del conjunto de Entrenamiento para el Modelo 1, con mala distribución de los datos, sin normalizar.




Figura 11. Resultados del conjunto de Entrenamiento para el Modelo 1, con mala distribución de los datos, normalización.




Figura 12. Resultados del conjunto de Entrenamiento para el Modelo 1, con mejor distribución de los datos, sin normalizar. Presenta comportamiento irregular en la exactitud.




Figura 13. Resultados del conjunto de Entrenamiento para el Modelo 1, con mejor distribución de los datos, normalización.

Cuadro VIII
RESULTADOS MODELO 2, SIN BUENA DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.224	88.462 %
Validación	-	71.429 %

menos sobreentrenado, pudiendo ser un buen candidato para pasar a la etapa de Pruebas.

■ Modelo 2:

Resumen de los resultados generales obtenidos, presentes en los cuadros VIII, IX, X y XI.

Resultados obtenidos con el conjunto de Entrenamiento, visibles en las gráficas 14, 15, 16 y 17.

Como podemos observar en los resultados, el Modelo 2 con mejor distribución de los datos y con los mismos normalizados, presente en el cuadro XI, supera al resto de las versiones pues tiene mejores resultados en la exactitud del conjunto de Entrenamiento y de Validación, pudiendo ser un buen candidato para pasar a la etapa de Pruebas.

■ Modelo 3:

Resumen de los resultados generales obtenidos, presentes en los cuadros XII, XIII, XIV y XV.

Resultados obtenidos con el conjunto de Entrenamiento, visibles en las gráficas 18, 19, 20 y 21.

Como podemos observar en los resultados, el Modelo 3 con mejor distribución de los datos y con los mismos normalizados, presente en el cuadro XV, supera al resto de las versiones pues tiene mejores resultados en la exactitud del conjunto de Entrenamiento y de Validación, pudiendo ser un buen candidato para pasar a la etapa de

Cuadro IX
RESULTADOS MODELO 2, SIN BUENA DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.147	94.505 %
Validación	-	73.626 %

Cuadro X
RESULTADOS MODELO 2, MEJOR DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.263	90.659 %
Validación	-	73.626 %

Cuadro XI
RESULTADOS MODELO 2, MEJOR DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.142	95.604 %
Validación	-	73.626 %




Figura 14. Resultados del conjunto de Entrenamiento para el Modelo 2, con mala distribución de los datos, sin normalizar. Presenta comportamiento irregular en la exactitud.




Figura 15. Resultados del conjunto de Entrenamiento para el Modelo 2, con mala distribución de los datos, normalización.




Figura 16. Resultados del conjunto de Entrenamiento para el Modelo 2, con mejor distribución de los datos, sin normalizar.




Figura 17. Resultados del conjunto de Entrenamiento para el Modelo 2, con mejor distribución de los datos, normalización.

Cuadro XII
RESULTADOS MODELO 3, SIN BUENA DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.307	89.56 %
Validación	-	75.824 %

Cuadro XIII
RESULTADOS MODELO 3, SIN BUENA DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.084	98.352 %
Validación	-	72.527 %

Cuadro XIV
RESULTADOS MODELO 3, MEJOR DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.659	54.945 %
Validación	-	48.352 %

Cuadro XV
RESULTADOS MODELO 3, MEJOR DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.087	97.802 %
Validación	-	74.725 %




Figura 18. Resultados del conjunto de Entrenamiento para el Modelo 3, con mala distribución de los datos, sin normalizar.




Figura 19. Resultados del conjunto de Entrenamiento para el Modelo 3, con mala distribución de los datos, normalización.




Figura 20. Resultados del conjunto de Entrenamiento para el Modelo 3, con mejor distribución de los datos, sin normalizar. Presenta comportamiento irregular y en extremo errático en la exactitud, Modelo para NO tener en cuenta.




Figura 21. Resultados del conjunto de Entrenamiento para el Modelo 3, con mejor distribución de los datos, normalización.

Pruebas.

■ **Modelo 4:**

Resumen de los resultados generales obtenidos, presentes en los cuadros XVI, XVII, XVIII.

Resultados obtenidos con el conjunto de Entrenamiento, visibles en las gráficas 22, 23, 24 y 25.

Como podemos observar en los resultados, el Modelo 4 con mejor distribución de los datos y con los mismos normalizados, presente en el cuadro XVII, supera al resto de las versiones pues tiene mejores resultados en la exactitud del conjunto de Entrenamiento y de Validación, pero, debido al comportamiento errático de todas y cada una de las versiones del modelo 4, no podemos tener a ninguno como posibilidad para la etapa de Pruebas pues no sabemos cómo se comporte realmente con su baja fiabilidad.

Cuadro XVI
RESULTADOS MODELO 4, SIN BUENA DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.571	74.176 %
Validación	-	23.077 %

Cuadro XVII
RESULTADOS MODELO 4, SIN BUENA DISTRIBUCIÓN, CON NORMALIZACIÓN

Etapas	Pérdida	Exactitud
Entrenamiento	0.018	99.451 %
Validación	-	73.626 %

Cuadro XVIII
RESULTADOS MODELO 4, MEJOR DISTRIBUCIÓN, SIN NORMALIZACIÓN

Etap	Pérdida	Exactitud
Entrenamiento	0.266	90.11 %
Validación	-	70.33 %

Cuadro XIX
RESULTADOS MODELO 4, MEJOR DISTRIBUCIÓN, CON NORMALIZACIÓN

Etap	Pérdida	Exactitud
Entrenamiento	0.005	100.0 %
Validación	-	71.429 %




Figura 25. Resultados del conjunto de Entrenamiento para el Modelo 4, con mejor distribución de los datos, normalización. Presenta comportamiento irregular y en extremo errático en la exactitud, Modelo para NO tener en cuenta.

Cuadro XX
RESULTADOS MODELO X, MEJOR DISTRIBUCIÓN, CON NORMALIZACIÓN

Etap	Pérdida	Exactitud
Entrenamiento	0.632	- %
Validación	-	- %

■ **Modelo X:**Para este modelo, tuvimos un acercamiento diferente. Para utilizar nuestro framework de forma competente, construimos con él el modelo que mejores resultados tuvo de entre los anteriores. Así, el resumen de los resultados generales obtenidos está presente en el cuadro XX.

Resultados obtenidos con el conjunto de Entrenamiento, visibles en la gráfica 26.

Así, viendo todos los resultados de las mejores versiones de cada modelo, comparamos cada uno de ellos en el cuadro XXI.

Así, con pruebas y evidencia en resultados, el mejor modelo resulta ser el Modelo 3, con mejor Distribución de los datos, y con los mismos estando Normalizados. Este es el modelo seleccionado, pudiendo así entrar ahora en la etapa de Pruebas con el conjunto de pruebas.

La arquitectura gráfica de este modelo seleccionado corres-




Figura 22. Resultados del conjunto de Entrenamiento para el Modelo 4, con mala distribución de los datos, sin normalizar. Presenta comportamiento irregular en la exactitud.




Figura 23. Resultados del conjunto de Entrenamiento para el Modelo 4, con mala distribución de los datos, normalización. Presenta comportamiento irregular y en extremo errático en la exactitud, Modelo para NO tener en cuenta.




Figura 24. Resultados del conjunto de Entrenamiento para el Modelo 4, con mejor distribución de los datos, sin normalizar. Presenta comportamiento irregular en la exactitud.




Figura 26. Resultados del conjunto de Entrenamiento para el Modelo X, con mejor distribución de los datos, normalización.

Cuadro XXI
RESUMEN DE RESULTADOS

Modelo	Pérdida E.	Exactitud E.	Exactitud V.
Modelo 1	0.285	85.714 %	73.626 %
Modelo 2	0.142	95.604 %	73.626 %
Modelo 3	0.087	97.802 %	74.725 %
Modelo X	0.632	- %	- %

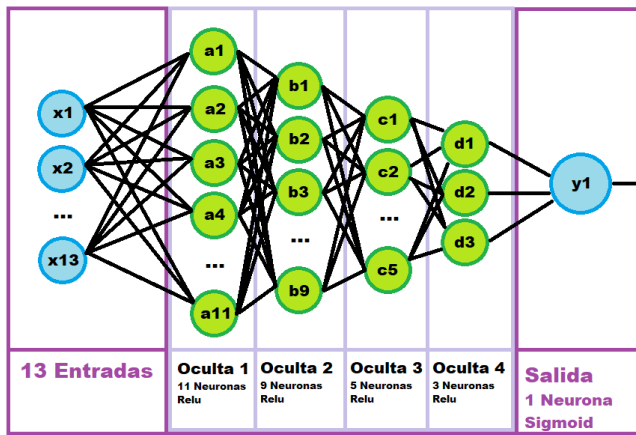


Figura 27. Arquitectura del modelo seleccionado, siendo este el Modelo 3.




Figura 28. Resultados del conjunto de Pruebas para el Modelo 3. Los puntos Azules indican el resultado esperado, presente en el conjunto de Prueba. Los puntos Naranjas corresponden al resultado obtenido por la predicción. Como se puede apreciar, y a diferencia de los puntos azules, los puntos naranjas corresponden a valores no enteros, por lo que es necesario aproximar. El eje horizontal representa el número de paciente analizado (pacientes que van desde el 273 hasta el 303), y el eje vertical representa valores entre 1 y 0, si cada paciente de ser o no propenso a sufrir de ataques cardíacos.

ponde a la que se puede ver en la figura 27.

Teniendo esto en cuenta, prediciendo con el modelo seleccionado y haciendo uso del conjunto de Prueba, los resultados obtenidos corresponden a los vistos en la gráfica 28.

Teniendo en cuenta que los resultados arrojados por la red no son enteros, decidimos tomar aproximaciones que no se tomaron en cuenta para el cálculo de la exactitud, pero si para cuando se decida enseñar y verificar los resultados. En específico, decidimos con ayuda del estudio publicado en el Journal of the American Medical Association, clasificar a los pacientes como SI propensos a sufrir ataques cardíacos si el resultado arrojado por la red es una probabilidad superior al **65 %**, pues ya se incide en un riesgo considerable para el paciente que es mejor tener en cuenta para su cuidado y para la prevención temprana de posibles padecimientos. Los resultados ajustados se pueden ver en la figura 29.

Nota: En las gráficas 28 y 29, en caso de no visualizarse puntos azules sino solo naranjas en alguno de los pacientes, significa que el resultado obtenido ES el resultado esperado.

Para una correcta visualización de los resultados finales, en la figura 30 presentamos una matriz de confusión donde de forma específica y diciente, contamos cuántos casos fue capaz el modelo de clasificar correctamente y cuántos no.




Figura 29. Resultados ajustados del conjunto de Pruebas para el Modelo 3. El eje horizontal representa el número de paciente analizado (pacientes que van desde el 273 hasta el 303), y el eje vertical representa valores entre 1 y 0, si cada paciente de ser o no propenso a sufrir de ataques cardíacos.




Figura 30. Resultados en matriz de confusión de las predicciones realizadas por el Modelo 3. El color azul oscuro en la diagonal principal indica que la enorme mayoría de los casos clasificados fueron correctos siendo los Verdaderos Positivos y los Verdaderos Negativos. En la diagonal secundaria, tenemos los Falsos Positivos y los Falsos Negativos, significando que clasificó de forma errada algunos elementos de ambas categorías.

Finalmente, la exactitud en Pruebas del modelo alcanza un valor de **86.667 %** con un tiempo de ejecución total de **7 minutos** aproximadamente (incluyendo el tiempo de Entrenamiento y Validación). Esto no solo significa que logramos cumplir con ambas métricas establecidas, sino también demuestra una clara mejoría en el resultado de la exactitud en Entrenamiento alcanzado en nuestro trabajo previo, superando su 88.462 %.

En la tabla XXI podemos ver un resumen de los resultados obtenidos finalmente.

De esta forma, se construyó y evaluó varios modelos de redes neuronales simples aplicados a problemas de clasificación.

Cuadro XXII
RESUMEN DE RESULTADOS DEL MODELO 3

Modelo	Pérdida E.	Exactitud E.	Exactitud V.	Exactitud P.
Modelo 3	0.087	97.802 %	74.725 %	86.667 %

ción, construyendo uno que logra cumplir con las métricas establecidas y arroja resultados favorables para el desarrollo de sistemas inteligentes, y resultados favorables para el posible uso de herramientas de ayuda para profesionales de la salud del corazón.

VI. CONCLUSIONES

En este estudio, se exploró el uso de redes neuronales simples para abordar un problema de clasificación en el que se busca determinar la propensión de pacientes a sufrir ataques al corazón. Se eligió esta técnica de aprendizaje automático debido a su capacidad para procesar y analizar grandes conjuntos de datos complejos, y su efectividad en la detección de patrones y características relevantes para la clasificación de casos.

El problema de clasificación se abordó mediante el diseño y entrenamiento de diferentes y variados modelos de redes neuronales simples, que se ajustaron a las características y requerimientos específicos de la base de datos utilizada en el estudio. Se llevaron a cabo diversas técnicas de preprocesamiento de datos para garantizar la calidad y homogeneidad de los mismos.

Se evaluó el rendimiento de cada modelo mediante el uso de medidas de exactitud, pérdida y tiempo, para finalmente llevar a cabo pruebas para validar la efectividad del mejor de los modelos en la detección de pacientes propensos a sufrir ataques al corazón.

Los resultados obtenidos son prometedores, y ratifican que el uso de redes neuronales simples es una herramienta valiosa en la detección temprana de casos de riesgo cardiovascular. Sin embargo, se reconoce la necesidad de realizar investigaciones adicionales para evaluar la generalización y aplicabilidad del modelo en diferentes entornos y poblaciones, utilizando por ejemplo diferentes datasets de similares características.

Específicamente, el mejor de los modelos posee la siguiente configuración:

- Entradas: 13
- Capas ocultas: 4
- Neuronas por Capa Oculta: 11, 9, 5, 3
- Funciones de activación Capas Ocultas: Relu
- Salidas: 1
- Función de activación Capas de Salida: Sigmoide
- Épocas: 500
- Costo: Entropía cruzada Binaria
- Optimizador: Adam
- Pérdida en Entrenamiento: 0.087
- Exactitud en Pruebas: 86.667 %

Por último, podemos afirmar que la experimentación con redes neuronales simples es fundamental en el desarrollo de sistemas de prevención y tratamiento de ataques al corazón. A medida que se agregan más datos al dataset utilizado para entrenar la red neuronal, se puede mejorar la exactitud de los resultados. Esto es especialmente importante en el caso de enfermedades cardíacas, donde una detección temprana y precisa puede marcar la diferencia entre la vida y la muerte.

Sin embargo, es importante tener en cuenta que la cantidad de datos no es lo único que importa. La calidad de los datos

y la forma en que se preprocesan también pueden afectar significativamente la exactitud de los resultados. Además, probar diferentes arquitecturas y técnicas de regularización puede ayudar a mejorar aún más la exactitud de la red neuronal.

Finalmente, el uso de nuestro framework arroja resultados a tener en consideración aunque no alcancen los obtenidos con Keras. Es un trabajo en desarrollo que demuestra ir bien encaminado.

En resumen, la experimentación con diferentes técnicas y arquitecturas es fundamental en la creación de sistemas para la prevención y tratamiento de enfermedades cardíacas por medio de la clasificación, y el uso de grandes cantidades de datos puede ser beneficioso para mejorar la exactitud de los resultados.

VII. TRABAJO FUTURO

Como trabajo futuro, nos gustaría abordar la regularización, técnicas y herramientas, para de los datos del dataset tomado buscando mejorar el rendimiento de la red neuronal en situaciones de sobre ajuste. Más datos, aplicación a más datasets, mejores resultados (posiblemente). Además, consideramos que sería interesante probar otros tipos de redes neuronales, como las convolucionales, para evaluar su capacidad para manejar este tipo de datos.

Otro aspecto importante a considerar es la posibilidad de encontrar una manera fácil y práctica de desplegar la red para su uso por profesionales. Para ello, podríamos explorar diferentes opciones de despliegue, como la creación de una API o el uso de contenedores de Docker para su implementación en diferentes entornos. Esto permitiría una mayor accesibilidad y utilización de la red neuronal en diferentes aplicaciones y contextos profesionales.

Por último, queremos investigar y poder señalar correctamente el porqué del comportamiento de varios de los modelos creados, pues en los errores es donde se encuentra la información más valiosa. Quizá entendiendo el porqué de esos comportamientos erráticos nos permita mejorar el rendimiento y la exactitud del modelo finalmente seleccionado.

REFERENCIAS

- [1] Enfermedad cardíaca. (2022, agosto 25). Mayo Clinic. <https://www.mayoclinic.org/es-es/diseases-conditions/heart-disease/symptoms-causes/syc-20353118>
- [2] Barbosa, J. E. (s/f). Breve historia del corazón y de los conocimientos cardiológicos. Fbbva.es, de https://www.fbbva.es/microsites/salud_cardio/mult/fbbva_libroCorazon_cap1.pdf
- [3] Datos médicos digitales - IIC. (2022, marzo 3). Instituto de Ingeniería del Conocimiento. <https://www.iic.uam.es/soluciones/salud/analisis-datos-salud/datos-medicos-digitales/>
- [4] Nowak, S. (2022, diciembre 7). Modelos predictivos ¿Qué son y para qué se usan? Nuclio Digital School. <https://nuclio.school/modelos-predictivos-que-son-y-usos/>
- [5] Marcadores cardíacos. (s/f). Labtestsonline.es. Recuperado el 1 de junio de 2023, de <https://www.labtestsonline.es/tests/marcadores-cardiacos>
- [6] García, J. D. V. (2019, febrero 28). Redes neuronales desde cero (I) - Introducción. Iartificial.net. <https://www.iartificial.net/redes-neuronales-desde-cero-i-introduccion/>
- [7] Ruiz, C. A., & Basualdo, M. S. (s/f). Edu.ar, de https://www.fro.utn.edu.ar/repositorio/catedras/quimica/5_anio/orientadora1/monograis/matich-redesneuronales.pdf

- [8] Na. (2018, mayo 29). Una sencilla Red Neuronal en Python con Keras y Tensorflow. Aprende Machine Learning. <https://www.aprendemachinellearning.com/una-sencilla-red-neuronal-en-python-con-keras-y-tensorflow/>
- [9] Keras: biblioteca de código abierto para crear redes neuronales. (s/f). IONOS Digital Guide, de <https://www.ionos.es/digitalguide/online-marketing/marketing-para-motores-de-busqueda/que-es-keras/>
- [10] Adam. (s/f). Keras.Io, de <https://keras.io/api/optimizers/adam/>
- [11] Probabilistic losses. (s/f). Keras.Io, de https://keras.io/api/losses/probabilistic_losses/
- [12] Rahman, R. (2021). Heart attack analysis & prediction dataset [Data set].
- [13] Rocha, S. A. (s/f). IAAP_HeartAttack.
- [14] Rocha, S. A. (s/f-b). IAAP_NeuralNetsFramework.
- [15] Zimroz, R., & Siwek, K. (2001). Heart disease diagnosis using neural networks. *Control and Cybernetics*, 30(4), 757-775.
- [16] Osareh, M. R., Shiri, S., & Khorsandi, M. T. (2008). Prediction of heart disease using artificial neural network. *Journal of medical systems*, 32(6), 497-502.
- [17] Acharya, U. R., Fujita, H., Sudarshan, V. K., Oh, S. L., Adam, M., & Tan, J. H. (2017). Automated detection of coronary artery disease using different durations of ECG segments with convolutional neural network. *Knowledge-Based Systems*, 132, 62-71.
- [18] Ceylan, R., Özcanhan, M. H., & Özcan, T. (2020). Prediction of heart disease using ensemble models with feature selection methods. *Computer Methods and Programs in Biomedicine*, 196, 105623.
- [19] Fakoor, R., Ladhak, F., Nazi, A., & Huber, M. (2013). Using deep learning to enhance cancer diagnosis and classification. In *Proceedings of the 30th International Conference on Machine Learning (ICML-13)* (pp. 909-916).
- [20] Keras: Deep learning for humans. (n.d.). Keras.Io. Retrieved March 21, 2023, from <https://keras.io>
- [21] Pandas documentation — pandas 1.5.3 documentation. (n.d.). Pydata.org. Retrieved March 21, 2023, from <https://pandas.pydata.org/docs/>
- [22] Matplotlib documentation — Matplotlib 3.7.1 documentation. (n.d.). Matplotlib.org. Retrieved March 21, 2023, from <https://matplotlib.org/stable/index.html>
- [23] Singh, R., & Rajesh, E. (2019). Prediction of heart disease by clustering and classification techniques. *International Journal of Computer Sciences and Engineering*, 7(5), 861-866. <https://doi.org/10.26438/ijcse/v7i5.861866>